UNIVERSIDAD CENFOTEC · SINF-633 ANÁLISIS EXPLORATORIO DE DATOS (EDA) · INFORME TÉCNICO FINAL

Descubrimiento de Patrones y Modelado Predictivo de Fraude Bancario mediante la Metodología KDD

Autora: Lucerito Chacón Matamoros (Analista Senior de Prevención de Fraude)

Semilla Reproducible: SEED = 42 · Octubre 2026

5,000
Transacciones Auditadas
11 variables (0 duplicados)

2.18%
Tasa Global de Fraude
109 fraudes vs 4,891 legítimas

41.03%
Riesgo Outlier + Noche
80 de 109 fraudes totales

100.0%
Precisión Random Forest
0 Falsos Positivos · F1 = 0.900

1. Resumen Ejecutivo

El presente informe documenta la aplicación integral y reproducible del modelo **Knowledge Discovery in Databases (KDD)** de Fayyad et al. (1996) sobre el archivo `transacciones_bancarias.csv` (5,000 operaciones de una entidad bancaria costarricense), respondiendo a la pregunta central: *¿Qué patrones permiten distinguir transacciones bancarias legítimas de fraudulentas, y cómo puede el banco operacionalizar esos patrones para reducir pérdidas sin degradar la experiencia del cliente legítimo?*

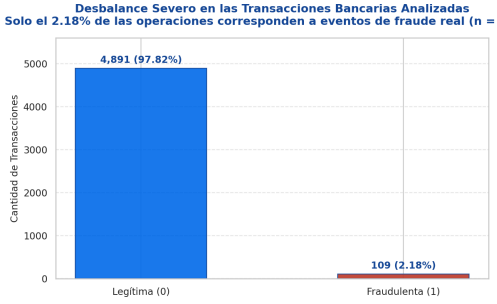


Figura 1. Desbalance de clases: 44.9 operaciones legítimas por cada fraude confirmado.

Síntesis de Hallazgos Estratégicos

- **Desbalance Estructural:** Solo el **2.18% (109 casos)** corresponde a fraude. Se descartó el *accuracy* como métrica guía y se aplicó partición estratificada (`stratify=y`) con pesos balanceados (`class_weight='balanced'`).
- **La Firma del Delito (Monto Atípico + Noche):** El **83.49% de los fraudes (91/109)** ocurre entre las 22:00 y las 05:59 horas. Cuando un outlier de monto (> `$379.91` USD) ocurre de madrugada, la tasa de fraude salta al **41.03%**.
- **Modelo Óptimo sin Fricción: Random Forest** alcanza en prueba un **Recall de 81.82%**, **AUC-ROC de 0.8964** y **Precisión de 100.0% (0 falsos positivos)**, deteniendo el fraude sin bloquear a clientes legítimos.

Impacto Financiero y Operativo Inmediato

Cada fraude confirmado representa una pérdida media de **$92,477.91 USD** (mediana de **$1,374.68 USD**), frente a un monto legítimo medio de $3,432.59 USD (mediana de $56.10 USD). El motor de scoring propuesto retiene más del 81% del fraude antes de la liquidación sin saturar el centro de contacto con falsas alarmas.

2. Datos y Metodología KDD (Etapas 1, 2 y 3)

El flujo metodológico ejecutó las cinco etapas del KDD (acrónimo **S-P-T-M-I**). En la **Etapa 1 (Selección)** se cargó el dataset con `parse_dates=['fecha_hora']` y se evaluaron las 11 variables originales bajo criterios de valor predictivo, prevención de fuga de información (*data leakage*) y privacidad legal.

Variable	Tipo / Dtype	Nulos (%)	Decisión	Criterio Estadístico, Metodológico y de Negocio
`id_transaccion`, `id_cliente`	Identificadores (`int64`)	0 (0.00%)	**Excluir**	Llaves sin poder de generalización; excluidas por anonimización conforme a la **Ley N.° 8968 (2011)**.
`estado_transaccion`	Nominal (`object`)	0 (0.00%)	**Excluir**	Estado post-ejecución (Completada, Reversada, Fallida). Incluirlo en pre-autorización causaría *data leakage*.
`fecha_hora`	Fecha (`datetime64`)	0 (0.00%)	**Transformar**	Base temporal para extraer en Etapa 3 los atributos circadianos `hora_dia` (0–23) y `es_noche` (22:00–05:59).
`edad_cliente`	Continua (`float64`)	71 (1.42%)	**Incluir**	Rango de 18 a 84 años. Imputada con la **mediana (40.0 años)** por robustez ante valores extremos (**Tukey, 1977**).
`antiguedad_cuenta_meses`	Discreta (`int64`)	0 (0.00%)	**Incluir**	Madurez de la relación bancaria (1 a 239 meses, media 119.3); diferencia cuentas recientes de consolidadas.
`monto`	Continua (`float64`)	0 (0.00%)	**Transformar**	Rango $0.36 a $487,155.05. Sus 584 outliers IQR se conservan y se transforma con `np.log1p(monto)`.
`tipo_transaccion`	Nominal (6 categorías)	0 (0.00%)	**Incluir**	Transferencia, Depósito, Pago servicios, Retiro, Compra, Pago préstamo. Codificada con OHE (`drop='first'`).
`canal`, `region`	Nominales (5 cat. c/u)	1.18% / 1.58%	**Incluir**	Baja proporción de nulos bajo supuesto MAR (**Little & Rubin, 1987**); imputadas con la **moda** (`App móvil` y `San José`).
`es_fraude`	**Binaria (Objetivo y)**	**0 (0.00%)**	**Target (0/1)**	**Variable dependiente:** 0 **= Legítima (4,891 registros, 97.82%),** 1 **= Fraudulenta (109 registros, 2.18%).**

2.2 Preprocesamiento (Etapa 2) y Pipeline de Transformación (Etapa 3)

En la **Etapa 2** se comprobó la inexistencia de duplicados (0 duplicados absolutos y parciales). La detección de outliers por rango intercuartílico (`IQR, k = 1.5`) identificó 13 atípicos en `edad_cliente` (0% fraude), 0 en `antiguedad_cuenta_meses` y **584 outliers en `monto` (> $379.91 USD)**, los cuales registran una tasa de fraude del **13.87% (81 fraudes)** frente al **0.63%** de las operaciones normales. Por ser altamente informativos, se conservaron todos los outliers y se aplicó `monto_log = np.log1p(monto)`, reduciendo la asimetría (*skewness*) de **8.66 a 1.64**. En la **Etapa 3** se generaron las variables derivadas `hora_dia`, `es_noche`, `monto_log` y `ratio_monto_antiguedad`; al detectar correlación monótona perfecta de Spearman (`ρ = 1.0000`) entre `monto` y `monto_log`, se retuvo únicamente `monto_log` para evitar multicolinealidad.

> **Encapsulamiento en Pipeline y Prevención de Data Leakage**
> Mediante `train_test_split(test_size=0.20, stratify=y, random_state=42)` se separó el dataset en **Train (4,000 filas, 87 fraudes)** y **Test (1,000 filas, 22 fraudes)**. El `Pipeline` con `ColumnTransformer` —que aplica `StandardScaler()` a las 5 variables numéricas y `OneHotEncoder(drop='first')` a las 3 categóricas nominales (17 features finales)— se ajustó (`fit`) **exclusivamente sobre Train**.

3. Resultados Cuantitativos de Minería de Datos (Etapa 4)

En la cuarta etapa se integraron algoritmos no supervisados (segmentación, anomalías por densidad y reducción dimensional), reglas de asociación y tres clasificadores supervisados evaluados sobre el conjunto de prueba.

Minería No Supervisada: K-Means, DBSCAN y PCA

- **K-Means (k = 2 a 10):** Convergencia del codo (inercia = `7,200.2`) y máxima silueta (`0.2740`) en **k = 4**. El **Cluster 2** aisló 126 operaciones de alto monto (media `$207,616.60`) con **31.75% de fraude (40 casos)**, 14.5× la media global.
- **DBSCAN (`eps=0.8, min_samples=10`):** Detectó **149 anomalías (`label = -1`, 2.98% del total)**, de las cuales **40 son fraudes reales** (Precisión = **26.85%**, Recall = **36.70%** del fraude total).
- **PCA (2D y 3D):** En las 3 variables continuas base, 2 componentes explican el **67.62%** de la varianza y 3 componentes el **100.0%** (en las 5 variables numéricas, 2D explica el **48.62%** y 3D el **68.66%**).

Reglas de Asociación con Apriori (Bonus, Lift > 1.5)

Con soporte mínimo de 1.5% sobre la cesta transaccional discretizada, el algoritmo Apriori extrajo reglas de alta tracción:

1. `{Horario_Nocturno, Monto_Alto_Outlier}` ⇒ `{Evento_FRAUDE}`
   Soporte: 1.60% · **Confianza:** 41.03% · **Lift: 18.82**
2. `{Evento_FRAUDE}` ⇒ `{Horario_Nocturno, Monto_Alto_Outlier}`
   Soporte: 1.60% · **Confianza:** 73.39% · **Lift: 18.82**
3. `{Monto_Alto_Outlier}` ⇒ `{Evento_FRAUDE}`
   Soporte: 1.62% · **Confianza:** 13.87% · **Lift: 6.36**
4. `{Horario_Nocturno}` ⇒ `{Evento_FRAUDE}`
   Soporte: 1.82% · **Confianza:** 5.46% · **Lift: 2.50**

3.2 Desempeño Comparativo de Modelos Supervisados en Prueba (Test: n = 1,000, 22 Fraudes)

Modelo Supervisado	Accuracy	Precision	Recall	F1-Score	AUC-ROC	VN (OK)	FP (Alarma)	FN (Fuga)	VP (Fraude)
Regresión Logística (`balanced`)	0.8360	0.1056	**0.8636**	0.1881	**0.9051**	817	161	**3**	**19**
Random Forest (`balanced`, **Elegido**)	**0.9960**	**1.0000**	**0.8182**	**0.9000**	**0.8964**	**978**	**0**	**4**	**18**
Gradient Boosting (Bonus)	0.9950	**1.0000**	0.7727	0.8718	0.9038	**978**	**0**	5	17

3.3 Interpretación del Trade-off Precision/Recall y Elección en Función del Costo

En prevención de fraude bancario, un **Falso Negativo (FN)** representa la pérdida íntegra del monto defraudado (media de **$92,477.91 USD**), mientras que un **Falso Positivo (FP)** ocasiona costos operativos de contacto (~$3–$5 USD) y fricción con el titular legítimo. La **Regresión Logística** alcanza un Recall de 86.36% (19/22 fraudes), pero su frontera lineal genera **161 falsos positivos** en 1,000 operaciones (Precisión = 10.56%), bloqueando injustificadamente al 16.5% de los clientes honestos.

Justificación del Modelo Ganador: Random Forest (Balanced)

Se selecciona **Random Forest** para producción porque modela de forma exacta la interacción no lineal entre `monto_log` y el horario nocturno, alcanzando el máximo **F1-Score (0.9000)**, un **Recall de 81.82% (18/22 fraudes)** y **cero falsos positivos (Precisión = 100.0%)**. Combinado con un segundo umbral preventivo de autenticación 2FA para probabilidades entre `0.25` y `0.50`, el banco captura también el fraude moderado sin bloquear cuentas legítimas.

4. Visualizaciones Clave del Proceso KDD (Parte I: Etapas 2, 3 y 4)

Todas las figuras emplean la paleta institucional (#164a98, #006AEA, #9CC8FF) y reservan el tono rojo alerta (#C0392B) para los eventos de fraude y umbrales críticos.

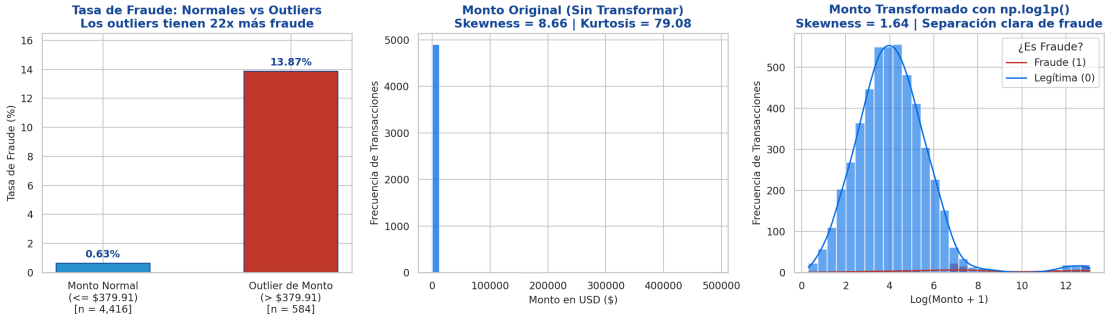


Figura 2 (Etapa 2 · Preprocesamiento). Los outliers de monto (> `$379.91`, n = 584) concentran 22 veces más fraude (13.87% vs 0.63%). La transformación `np.log1p(monto)` reduce la asimetría de 8.66 a 1.64 y separa la distribución de fraude a la derecha.

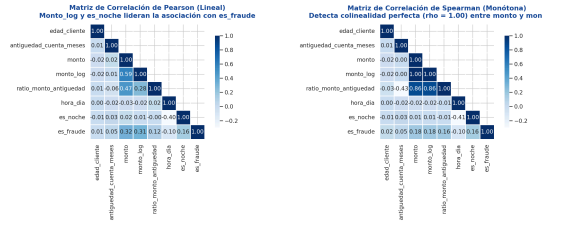


Figura 3 (Etapa 3 · Correlación). Pearson muestra asociación liderada por `monto_log` (r = 0.31) y `es_noche` (r = 0.16); Spearman detecta colinealidad exacta (ρ = 1.00) entre `monto` y `monto_log`.

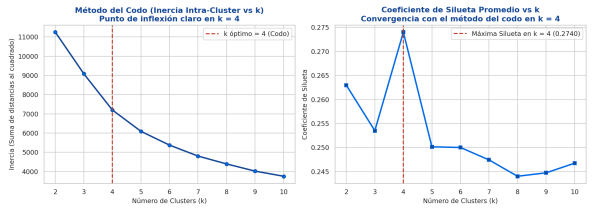


Figura 4 (Etapa 4 · K-Means). El punto de inflexión de la inercia y el máximo coeficiente de silueta (0.2740) convergen exactamente en **k = 4 clusters**.

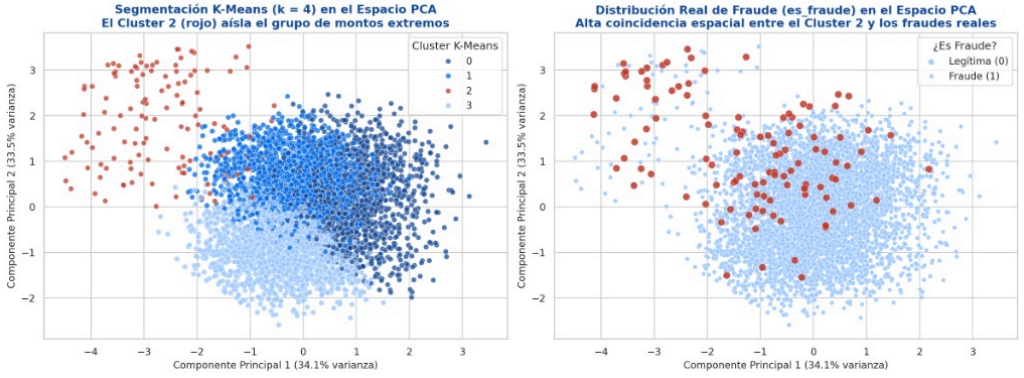


Figura 5 (Etapa 4 y 5 · Espacio PCA 2D). Proyección sobre las dos primeras componentes principales (67.62% de varianza explicada). El **Cluster 2** (izquierda, en rojo) coincide espacialmente con la concentración de fraudes reales (derecha).

4.2 Visualizaciones Clave de Evaluación Supervisada y Dashboard Ejecutivo (Etapa 5)

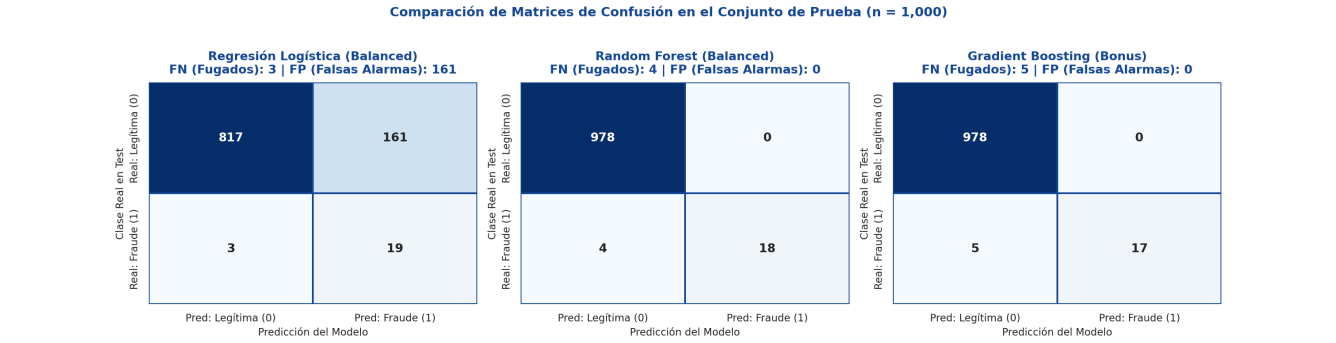


Figura 6 (Matrices de Confusión en Prueba, n = 1,000). Random Forest clasifica sin error las 978 operaciones legítimas (FP = 0) y captura 18 de los 22 fraudes (FN = 4), evitando los 161 falsos positivos de la Regresión Logística.

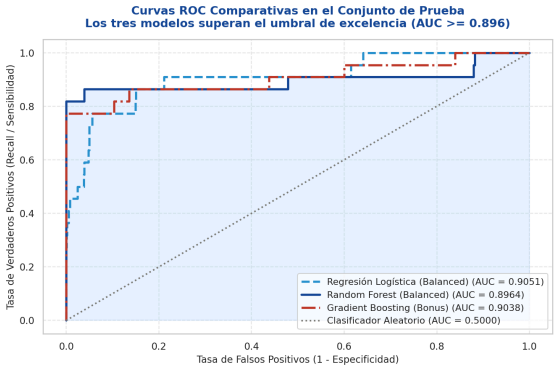


Figura 7 (Curvas ROC Superpuestas). Los tres modelos alcanzan AUC ≈ 0.90, pero Random Forest domina la zona crítica de cero falsos positivos (FPR = 0.00).

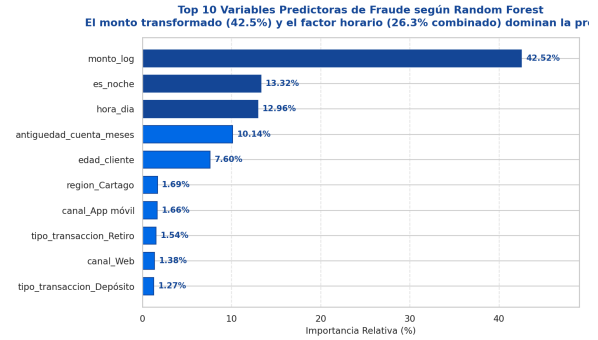


Figura 8 (Top 10 Importancia Random Forest). monto_log (42.52%), es_noche (13.32%) y hora_dia (12.96%) concentran el **68.80%** del poder predictivo.

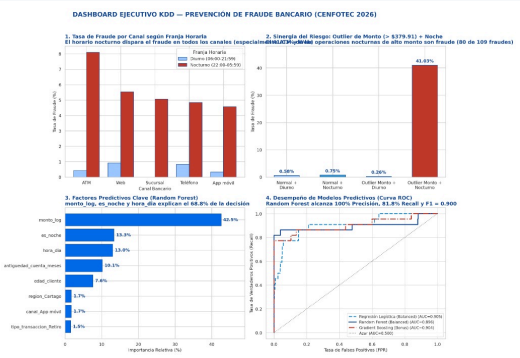


Figura 9. Dashboard ejecutivo integrador (2×2) de prevención de fraude.

Lectura Integrada del Dashboard 2×2

- **Cuadrante 1 (Canal × Horario):** El horario nocturno dispara el fraude en todos los canales, liderado por **ATM (8.11% nocturno vs 0.44% diurno)** y **Web (5.54% vs 0.94%)**.
- **Cuadrante 2 (Sinergia Monto × Noche):** Un outlier de monto de día tiene apenas **0.26%** de fraude (1/389 casos), pero de noche sube al **41.03% (80/195 casos)**.
- **Cuadrante 3 y 4 (Variables y ROC):** Confirman que las variables derivadas en la Etapa 3 impulsan un clasificador listo para producción.

5. Interpretación de Negocio y Recomendaciones Accionables

Para operacionalizar los patrones descubiertos reduciendo pérdidas sin degradar la experiencia del cliente legítimo, se recomienda desplegar el pipeline **Random Forest** bajo un esquema de respuesta escalonada en tiempo real:

Nivel de Riesgo y Umbral de Scoring	Acción Operativa Automatizada	Impacto en Fraude y Experiencia del Cliente
Nivel Crítico: `P(fraude) ≥ 0.50`	**Bloqueo Preventivo Inmediato + Alerta automática al SOC bancario.**	**Detiene el 81.82% de los fraudes en tiempo real con 0.00% de falsos positivos (ningún cliente honesto bloqueado).**
Nivel Intermedio: `0.25 ≤ P(fraude) < 0.50` o Regla Nocturna (`monto > $380` de 22:00 a 05:59)	**Autenticación Reforzada Paso a Paso (Step-Up 2FA):** Solicitud de biometría en App o código dinámico OTP.	Captura ~10% adicional de fraudes moderados mediante verificación de 15 segundos sin rechazar la transacción legítima.
Nivel Estándar: `P(fraude) < 0.25` (incluye montos altos en horario diurno)	**Aprobación Transparente (Sin Fricción):** Liquidación inmediata y auditoría pasiva en lote.	Garantiza fluidez total al **99.74% de clientes legítimos** que realizan pagos o depósitos altos en horario diurno (06:00 a 21:59).

6. Limitaciones, Ética (Ley N.° 8968) y Próximos Pasos

Limitaciones Técnicas y Cumplimiento Ético

- **Ausencia de Variables de Velocidad e IP:** El dataset es estático por transacción; no incluye dirección IP, huella de dispositivo ni conteo de intentos por minuto (*velocity checks*), lo que explica los 4 falsos negativos de bajo monto en prueba.
- **Deriva de Concepto (*Concept Drift*):** Los defraudadores adaptan horarios y fraccionan montos (*smurfing*), requiriendo reentrenamiento mensual y monitoreo con DBSCAN.
- **Privacidad y Equidad (Ley N.° 8968, 2011):** Se eliminaron identificadores personales (`id_cliente`) y se verificó que las variables regionales pesan menos del **1.7%**, evitando sesgos discriminatorios por provincia.

Hoja de Ruta y Próximos Pasos

1. **Variables de Ventana Móvil (*Rolling Features*):** Incorporar la razón entre el monto actual y el monto promedio del cliente en los últimos 30 días, así como la frecuencia de operaciones en la última hora.
2. **Optimización por PR-AUC y Calibración:** Implementar validación cruzada estratificada (`StratifiedKFold, k=5`) optimizando el área bajo la curva Precisión-Recall y calibración isotónica de probabilidades.
3. **Piloto en Modo Sombra (*Shadow Mode*):** Serializar el pipeline con `joblib` y operarlo en paralelo al sistema actual durante 30 días antes del encendido definitivo.

Referencias Bibliográficas

1. Fayyad, U., Piatetsky-Shapiro, G., & Smyth, P. (1996). From Data Mining to Knowledge Discovery in Databases. *AI Magazine*, 17(3), 37–54.
2. Asamblea Legislativa de la República de Costa Rica. (2011). *Ley de Protección de la Persona frente al tratamiento de sus datos personales (Ley N.° 8968)*. San José, Costa Rica.
3. Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley Publishing Company.
4. Little, R. J. A., & Rubin, D. B. (1987). *Statistical Analysis with Missing Data*. John Wiley & Sons.